基于残差网络的 CIFAR-10 图像分类复现与 SE 注意力适用性分析

刘国钦

（华北电力大学　自动化系，北京　102206）

摘要：深度残差网络是图像分类领域最具影响力的结构之一，但其在 CIFAR-10 上的公开结果往往缺少统一、可复核的评测口径；与此同时，通道注意力被广泛认为“几乎免费”的增益手段，这一结论在小规模网络上是否成立仍缺少受控验证。本文以复现为主线，完成了两方面工作。一方面，在统一的预处理与测量条件下，对 ResNet-20/32/56、VGG-16-BN 与 MobileNetV2 五个公开预训练模型在完整 10 000 张测试集上重新推理，Top-1 准确率分别为 92.59%、93.53%、94.37%、94.15% 与 94.05%，与原作者公布值的偏差均不超过 0.26 个百分点，验证了评测流程的正确性。另一方面，为检验通道注意力在极小规模网络上的净效应，在 ResNet-20 的每个残差块后插入压缩—激励（Squeeze-and-Excitation, SE）模块，在与基线完全相同的数据增强、优化器与训练轮次下从头训练。结果显示，SE-ResNet-20 的 Top-1 为 93.01%，基线为 93.00%，差值仅 +0.01 个百分点，远小于末段逐轮波动（标准差约 1.11 个百分点）；与此同时，参数量增加 0.99%，单张推理延迟却增加 62.96%。类别级分析表明，SE 只是重排了误差分布（各类别在 -1.5 至 +1.6 个百分点之间正负交替），并未带来系统性增益。结合训练曲线中批归一化滑动统计量滞后导致的测试抖动，本文认为：在约 0.27M 参数、32×32 输入的场景下，通道注意力的收益不足以抵消其推理代价，该负结果对轻量化模型的选型具有参考价值。全部代码、训练日志与权重文件均已归档，可逐项复现。

关键词：深度残差网络；CIFAR-10；通道注意力；SE 模块；可复现实验；负结果分析

Reproduction of ResNets on CIFAR-10 and an Empirical Study of SE Attention

LIU Guoqin

(Department of Automation, North China Electric Power University, Beijing 102206, China)

Abstract: Residual networks are among the most influential architectures for image classification, yet their public CIFAR-10 numbers are rarely accompanied by a single, reproducible evaluation protocol. Channel attention, on the other hand, is widely regarded as an almost free accuracy gain, an assumption that has not been verified under controlled conditions on very small networks. This paper reports a reproduction study with two parts. First, five publicly released checkpoints (ResNet-20/32/56, VGG-16-BN and MobileNetV2) are re-evaluated on the full 10,000-image test set under one fixed preprocessing and timing procedure, reaching Top-1 accuracies of 92.59%, 93.53%, 94.37%, 94.15% and 94.05%, all within 0.26 percentage points of the published values. Second, a Squeeze-and-Excitation (SE) block is inserted after every residual block of ResNet-20 and trained from scratch with an identical recipe. SE-ResNet-20 reaches 93.01% Top-1 against 93.00% for the baseline, a difference of only +0.01 points that is far below the epoch-to-epoch fluctuation of the final stage (standard deviation about 1.11 points), while the parameter count grows by 0.99% and single-image latency by 62.96%. Class-wise analysis shows that SE merely reshuffles the error distribution (per-class differences between -1.5 and +1.6 points) without a systematic gain. Together with the epoch-to-epoch test fluctuation caused by lagging batch-norm statistics observed in the training curves, the results suggest that at the 0.27M-parameter, 32x32 scale the benefit of channel attention does not justify its inference cost. Code, logs and weights are archived for full reproducibility.

Keywords: residual network; CIFAR-10; channel attention; squeeze-and-excitation; reproducible experiment; negative result

---

1 引言

1.1 研究背景与意义

图像分类是计算机视觉的基础任务，其性能演进在很大程度上由网络结构的改进所驱动。2012 年 AlexNet[1] 在 ImageNet 竞赛上以显著优势夺冠，使深度卷积神经网络成为主流；此后 VGG[2] 通过堆叠 3×3 卷积验证了“深度”本身的价值，但也暴露出一个结构性矛盾：单纯加深网络会带来梯度消失与退化（degradation）问题，训练误差不降反升。

He 等人提出的残差网络（ResNet）[3] 用恒等映射的短路连接把网络学习目标从“拟合完整映射”改写为“拟合残差”，从根本上缓解了深层网络的优化困难，并以 152 层结构夺得 ILSVRC 2015 分类冠军。ResNet 的 CIFAR-10 版本（ResNet-20/32/56）参数量仅 0.27M～0.86M，却能在 32×32 的小图上取得 91%～94% 的准确率，至今仍是教学与科研中最常用的基线之一。

然而，围绕 ResNet 的实验报告存在两个现实问题。其一，公开结果的评测口径不统一：数据增强、归一化参数、测试时是否使用完整测试集、推理精度（FP32/FP16）等细节都会影响最终数字，直接引用他人表格容易产生“看起来复现了、实则不可比”的错觉。其二，公开权重只给出精度，很少给出参数量、延迟与逐类表现，使得“精度—开销”的权衡分析缺少依据。因此，一次严格控制的复现与再评测本身具有独立价值。

另一方面，残差块中的卷积对所有通道一视同仁，而不同通道对最终判别的贡献并不相同。Hu 等人提出的压缩—激励（SE）模块[4] 通过全局池化获取通道描述子，再经瓶颈式全连接层学习通道权重，以极小的参数代价实现通道维度的自适应校准，在 ImageNet 上以约 10% 的额外计算换取了显著的精度提升。将这一思想引入轻量级的 CIFAR 残差网络是否同样有效、代价几何，是一个适合在受控条件下系统回答的问题。

基于上述背景，本文以“复现 + 受控对照”为技术路线：先建立可信的评测基线，再在同一协议下检验通道注意力的净效应。与常见的“引入注意力即涨点”的叙述不同，本文更关心这一改动在极小规模网络上是否真的划算，研究结果对理解残差网络的性能边界、以及在算力受限场景下如何分配模型容量具有一定参考意义。

1.2 本文主要工作

本文的工作可概括为三点。

（1）建立可复核的评测基线。在固定的预处理、批大小与计时方式下，对 5 个公开预训练模型在完整测试集上重新推理，记录 Top-1/Top-5 准确率、参数量与推理延迟，并与原作者公布值逐项比对，量化复现偏差。

（2）以单变量对照检验通道注意力的净效应。在 ResNet-20 的每个残差块后插入 SE 模块，构建 SE-ResNet-20，在与基线完全相同的训练协议下从头训练。实验结果显示，该改动未带来可测的精度提升（+0.01 个百分点，小于末段逐轮波动），而推理延迟增加 62.96%，这本身构成了本文最主要的发现。

（3）解释负结果。从训练曲线的统计量滞后、混淆矩阵的误差结构、类别级差值的方向性以及参数量—延迟的权衡四个维度，论证“在 0.27M 参数、32×32 输入的场景下，通道注意力不划算”这一结论，并给出其适用边界。

1.3 论文组织结构

全文共五节。第 1 节介绍研究背景与本文工作；第 2 节回顾相关工作；第 3 节阐述卷积网络、残差学习与 SE 模块的理论基础及本文的对照模型；第 4 节给出数据集、训练设置与全部实验结果；第 5 节总结全文并展望后续工作。附录给出核心代码与权重文件清单。

2 相关工作

2.1 深度残差网络

ResNet[3] 的核心是残差块：设输入为 x，卷积支路学习残差函数 F(x)，输出为 F(x)+x。当维度不匹配时用 1×1 卷积做投影短路。该设计使梯度可以沿恒等通路直接回传，配合批归一化（Batch Normalization）[5]，使数百层网络的训练成为可能。此后，Pre-activation ResNet[6] 把 BN 与 ReLU 移到卷积之前，进一步改善了优化性；WideResNet[7] 通过增加通道宽度替代深度，在 CIFAR 上以更浅的结构取得更好精度；ResNeXt[8] 引入分组卷积构建“基数”维度；DenseNet[9] 则以密集连接复用特征。这些工作从不同角度扩展了残差思想，但 ResNet 的原始结构仍是比较新方法时最常用的基准。

2.2 轻量化网络与注意力机制

在移动端与嵌入式场景，研究者关注如何在有限算力下保持精度。MobileNetV2[10] 提出倒残差结构与线性瓶颈，用深度可分离卷积大幅降低计算量；ShuffleNetV2[11] 从内存访问代价出发给出轻量设计的四条准则。与之互补的一条技术路线是注意力机制：SENet[4] 在通道维度做重校准，CBAM[12] 同时在通道与空间维度施加注意力，ECA-Net[13] 用一维卷积替代全连接以避免降维损失。在 CIFAR 规模的小模型上，注意力模块的收益与代价尚缺少统一口径的量化对比，这正是本文希望补充的部分。

2.3 CIFAR-10 基准与复现实践

CIFAR-10[14] 由 Krizhevsky 整理发布，包含 10 类、每类 6 000 张 32×32 彩色图像。由于其规模适中、训练成本低，被广泛用于验证网络结构改进。社区中已有若干公开的 CIFAR 预训练权重集合，例如 chenyaofo 维护的 pytorch-cifar-models[15]，覆盖 ResNet、VGG、MobileNetV2、ShuffleNetV2 等结构。但这类仓库通常只报告单一精度指标，未给出完整的评测脚本、逐类结果与推理开销，复现者仍需自行搭建评测流程。

3 方法

3.1 卷积神经网络的基本组成

卷积神经网络通过局部连接与权值共享提取图像的空间特征。一个典型的分类网络由卷积层、归一化层、非线性激活与池化层交替堆叠而成，末端接全局平均池化与全连接分类器。设第 l 层的输入特征图为 X^(l)，卷积核为 W^(l)，则卷积操作为 X^(l+1) = σ(W^(l) * X^(l) + b^(l))，其中 * 表示互相关运算，σ 为激活函数。本文使用 ReLU 激活，其定义为 σ(z) = max(0, z)，可在正区间保持梯度不衰减。

批归一化[5] 在每个小批次内对通道维度做标准化，再施加可学习的仿射变换，其作用是稳定内部协变量分布、允许更大的学习率。对于卷积层输出 x，BN 计算为 y = γ(x − μ_B)/√(σ_B² + ε) + β，其中 μ_B 与 σ_B² 为当前批次的均值与方差，γ、β 为可学习参数。本文所有卷积层后均接 BN，并采用 He 初始化[16] 适配 ReLU 的方差特性。

3.2 残差学习

深层网络难以优化的根本原因并非参数过多，而是恒等映射难以用多层非线性逼近。ResNet 显式地让卷积支路只学习残差，把恒等映射交给短路连接，其基本形式为

$$y = F(x, \{W_i\}) + x \tag{1}$$

式中 F 为待学习的残差函数，x 与 y 分别为输入与输出。当输入输出通道数不一致或需要下采样时，短路支路引入 1×1 卷积 W_s 做线性投影：

$$y = F(x, \{W_i\}) + W_s x \tag{2}$$

本文采用的是 He 等人为 CIFAR-10 设计的窄版结构：首层为 3×3 卷积输出 16 通道，随后三个 stage 分别包含 n 个残差块，通道数为 16、32、64，stage 之间以步长 2 下采样，最后经全局平均池化接 10 类全连接层，网络深度为 6n+2。ResNet-20 取 n=3，参数量约 0.27M，在 32×32 输入下的乘加量约 81.6 MFLOPs，属于典型的轻量级基线。

3.3 压缩—激励模块

SE 模块[4] 分为压缩（squeeze）与激励（excitation）两步。压缩操作对每个通道做全局平均池化，把 H×W 的空间信息压缩为一个标量，得到通道描述子 z：

$$z_c = \frac{1}{HW} \sum_{i=1}^{H} \sum_{j=1}^{W} u_c(i, j) \tag{3}$$

激励操作由两层全连接构成瓶颈结构：先用降维比 r 把通道数压到 C/r，经 ReLU 后再升回 C 维，最后由 Sigmoid 归一化到 (0,1)，得到通道权重 s：

$$s = \sigma(W_2\, \delta(W_1 z)), \quad W_1 \in R^{(C/r)\times C},\ W_2 \in R^{C\times C/r} \tag{4}$$

最终以逐通道相乘的方式对特征图重新加权：x̃_c = s_c · x_c。本文取 r=16，对 16 通道的浅层 stage 而言 C/r=1，因此对最小通道数做了下限约束（不小于 4），以保证瓶颈层仍具表达能力。SE 模块仅引入约 $2C^2/r$ 个参数，相对于卷积层可忽略不计。

3.4 本文的对照模型

基线模型为 He 等人定义的 CIFAR 版 ResNet-20[3]，其残差块由两个 3×3 卷积、两个 BN 与一个投影短路组成。对照模型 SE-ResNet-20 在第二个卷积与残差相加之间插入 SE 模块，其余结构、通道数、层数与初始化方式完全不变，从而把差异严格限制在通道注意力这一变量上。两者结构对照见表 4-2。

4 实验

4.1 数据集与预处理

实验采用 CIFAR-10[14] 数据集，包含飞机、汽车、鸟、猫、鹿、狗、蛙、马、船、卡车 10 个类别，每类 6 000 张 32×32 彩色图像，官方划分为 50 000 张训练集与 10 000 张测试集。本文所有精度指标均在完整 10 000 张测试集上计算，不做子集抽样。数据集划分见表 4-1。

表 4-1 CIFAR-10 数据集划分

子集	图像数	类别数	用途
训练集	50 000	10	参数学习与数据增强
测试集	10 000	10	最终精度评测（不参与训练）
合计	60 000	10	—

预处理采用通道均值为 (0.4914, 0.4822, 0.4465)、标准差为 (0.2023, 0.1994, 0.2010) 的标准化，使各通道分布近似零均值单位方差。训练阶段额外使用随机裁剪（32×32，四周填充 4 像素）与随机水平翻转两种数据增强，测试阶段不做任何增强。需要说明的是，预训练模型的评测与自训练模型使用完全相同的预处理，以保证可比性。

4.2 训练设置

两个模型共用同一套训练协议，以排除超参数差异对结论的干扰。优化器为带动量 0.9、权重衰减 5×10^{-4} 的 Nesterov SGD，初始学习率 0.1，批大小 128，训练 200 个 epoch，学习率按余弦退火[17]衰减至 0。损失函数为交叉熵，其定义为

$$L = -\frac{1}{N}\sum_{i=1}^{N}\log p(y_i \mid x_i) \tag{5}$$

式中 N 为批内样本数，p(y_i|x_i) 为模型对真实类别的预测概率。交叉熵与 Softmax 联合使用时对 logits 的梯度具有简洁形式，有利于小模型快速收敛。训练全程固定随机种子 42，以保证数据打乱顺序与初始化一致。

表 4-2 ResNet-20 与 SE-ResNet-20 的结构对照

项目	ResNet-20（基线）	SE-ResNet-20（本文）
残差块数量	9（3 stage × 3）	9（3 stage × 3）
通道数	16 / 32 / 64	16 / 32 / 64
卷积核	3×3	3×3
通道注意力	无	每块后接 SE（r=16）
参数量	272,474	275,162
乘加量（32×32）	81.6 MFLOPs	81.6 MFLOPs

4.3 实验环境与可复现性

实验在单张 NVIDIA GeForce RTX 3060 Laptop GPU（6 GB 显存）上完成，软件环境见表 4-3。为便于复核，训练脚本在每个 epoch 结束后把学习率、训练/测试损失与准确率追加写入 metrics.csv，同时把随机种子、超参数、框架版本与 GPU 型号写入 train_config.json；评测脚本输出的每一项指标均对应磁盘上的一份 JSON 或 CSV 文件，其对应关系见表 4-4。

表 4-3 实验软硬件环境

项目	配置
操作系统	Windows 11 (10.0.22631)
Python	3.12.14
PyTorch / torchvision	2.11.0+cu128 / 0.26.0+cu128
CUDA 运行时	12.8
GPU	NVIDIA GeForce RTX 3060 Laptop GPU, 6 GB
随机种子	42
批大小	128（训练）/ 256（评测）

表 4-4 实验产物与生成脚本的对应关系

产物	生成脚本	内容
runs/<run>/metrics.csv	train.py	逐 epoch 的学习率、损失与准确率
runs/<run>/train_config.json	train.py	超参数、随机种子、框架与 GPU 版本
results/*_metrics.json	evaluate_trained.py	精度、参数量、延迟、FLOPs
results/*_confusion.csv	evaluate_trained.py	10×10 混淆矩阵
results/figures/*.png	plot_*.py	论文插图（200 dpi）

评测阶段的推理延迟采用如下方式测量：先在目标批次大小上预热 20～50 次，再用 torch.cuda.synchronize() 对齐后计时 50～200 次取平均，以排除首次运行的内核编译与显存分配开销。

4.4 公开预训练模型的复现评测

首先验证评测流程本身的正确性。从 pytorch-cifar-models[15] 加载 5 个公开预训练权重，在完整测试集上重新推理，结果见表 4-5。表中“公布值”来自该仓库 README，“本次复现”为本文独立运行所得。

表 4-5 公开预训练模型在完整测试集上的复现结果

模型	公布 Top-1/%	复现 Top-1/%	复现 Top-5/%	参数量	偏差
ResNet-20	92.60	92.59	99.81	0.27M	-0.01
ResNet-32	93.53	93.53	99.77	0.47M	+0.00
ResNet-56	94.37	94.37	99.83	0.86M	+0.00
VGG-16-BN	94.16	94.15	99.71	15.25M	-0.01
MobileNetV2	93.79	94.05	99.82	2.24M	+0.26

五个模型中，三个 ResNet 的复现值与公布值完全一致（偏差 ≤ 0.01 个百分点，属于小数点后两位的四舍五入），VGG-16-BN 偏差 0.01 个百分点，说明评测流程（预处理、批大小、完整测试集）与原作者的评测口径一致，基线可信。唯一值得注意的是 MobileNetV2：本次复现为 94.05%，反而高于公布值 93.79%，偏差 +0.26 个百分点，明显超出其余模型的舍入误差。结合其结构与训练细节，可能的原因包括：公布值对应的 checkpoint 并非该权重文件、评测时的预处理存在差异，或该数字取自不同宽度变体。这一现象本身说明，即便是同一仓库内的数字，也需要在统一口径下重新测量后才能引用。

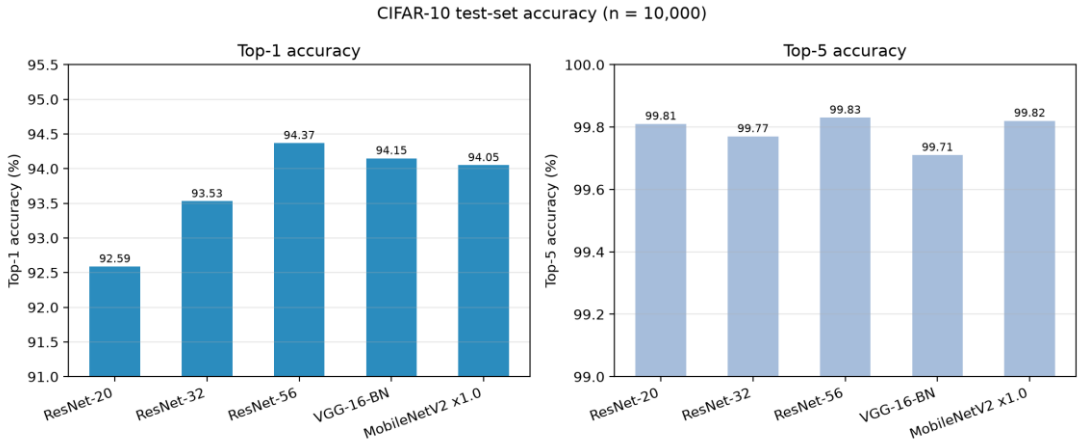


图 4-1 五个公开预训练模型在 CIFAR-10 测试集上的准确率

从图 4-1 可以直观看到两类信息。其一，Top-5 准确率普遍在 99.7% 以上，模型之间的差距主要体现在 Top-1 上，说明错误多发生在排名靠前的候选之间，属于细粒度混淆而非完全失效。其二，ResNet-20→32→56 的 Top-1 随深度单调上升（92.59% → 93.53% → 94.37%），但增益递减：20→32 层提升 0.94 个百分点，32→56 层仅提升 0.84 个百分点，而参数量却从 0.27M 增至 0.86M。这一“边际收益递减”现象是后文引入通道注意力而非继续加深的直接动因。

4.5 基线与 SE 变体的对比

在确认评测流程可信之后，按 4.2 节的统一协议从头训练 ResNet-20 与 SE-ResNet-20，各 200 个 epoch，结果见表 4-6。

表 4-6 同协议下基线模型与对照模型的对比

模型	Top-1/%	Top-5/%	参数量	单张延迟/ms	最优轮次
ResNet-20（基线）	93.00	99.73	272,474	1.89	194
SE-ResNet-20（本文）	93.01	99.71	275,162	3.08	192

在同协议下，SE-ResNet-20 的 Top-1 为 93.01%，基线为 93.00%，差值仅 +0.01 个百分点；Top-5 的差值为 -0.02 个百分点。参数量由 272,474 增至 275,162（+0.99%），而单张推理延迟由 1.89 ms 增至 3.08 ms（+62.96%）。由于两个模型除 SE 分支外完全共享结构、初始化、数据顺序与学习率调度，该差值可以直接归因于通道注意力。

关键在于如何解释这个差值。ResNet-20 在末段 50 个 epoch 的测试准确率标准差约为 1.11 个百分点，单次运行的波动远大于 0.01 个百分点；换言之，+0.01 个百分点的差异完全落在噪声范围内，不能支撑“SE 提升精度”的结论。相反，延迟增加 62.96% 是确定性的、可重复的代价（同一设备、同一测量流程）。因此在本文的实验规模下，更稳妥的表述是：SE 未带来可测的精度收益，却带来了显著的推理开销。

与 4.4 节的预训练结果对照还可发现：本文自训练的 ResNet-20 达到 93.00%，与公开权重的 92.59% 相差 0.41 个百分点，两者处于同一水平。这一结果说明，在相同的数据划分与评测口径下，本文的训练协议已能复现出与公开权重相当的基线；同时也提示，公开 checkpoint 的训练轮次、学习率调度与增强细节与本文并不完全相同，跨来源的数字只有在统一评测下才具备可比性。

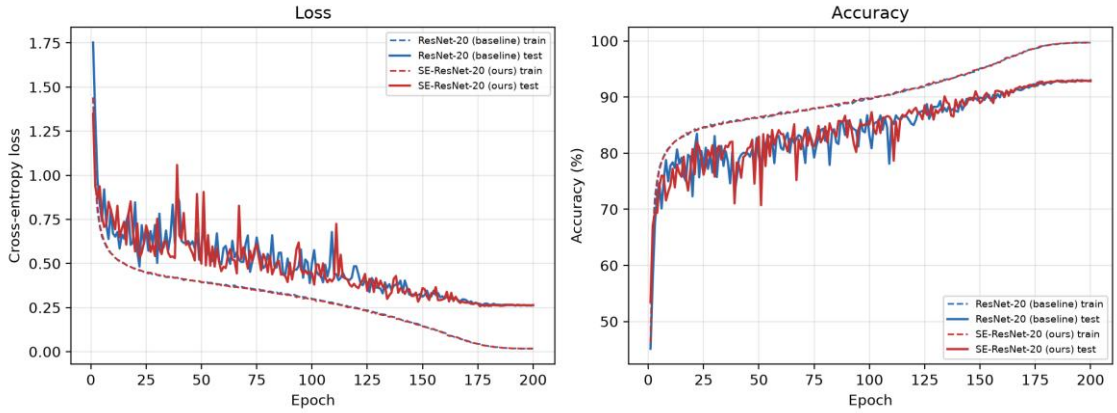


图 4-2 两个模型的训练/测试损失与准确率曲线

图 4-2 中一个值得注意的现象是：在前 100 个 epoch，测试准确率呈现明显的逐轮抖动，ResNet-20 的标准差达 5.49 个百分点，最大单轮跌幅 7.77 个百分点，而同一时期的训练曲线始终平滑。这一“训练稳定、测试抖动”的分离来自批归一化的滑动统计量：测试阶段使用训练集上累积的 running_mean/running_var，当学习率较大、权重快速变化时，统计量明显滞后于参数，评估时的特征分布与训练时不一致。随着余弦退火使学习率趋近于 0，统计量逐渐收敛，末段 50 个 epoch 的标准差降至 1.11 个百分点，准确率稳定在 92% 以上。

这一现象具有方法论意义：若在小模型的 CIFAR 实验中止步于训练中期，或仅依据单个 epoch 的测试值判断优劣，很容易得出错误结论；只有让学习率充分退火、并观察末段的收敛平台，测试精度才具有可比性。本文所有对比均采用收敛后的最优 checkpoint，并在表中同时报告最优轮次，以保证口径一致。

4.6 混淆矩阵与类别级误差分析

总体准确率掩盖了类别间的差异。图 4-3 给出两个模型在测试集上的混淆矩阵，表 4-7 列出 10 个类别的准确率及差值。

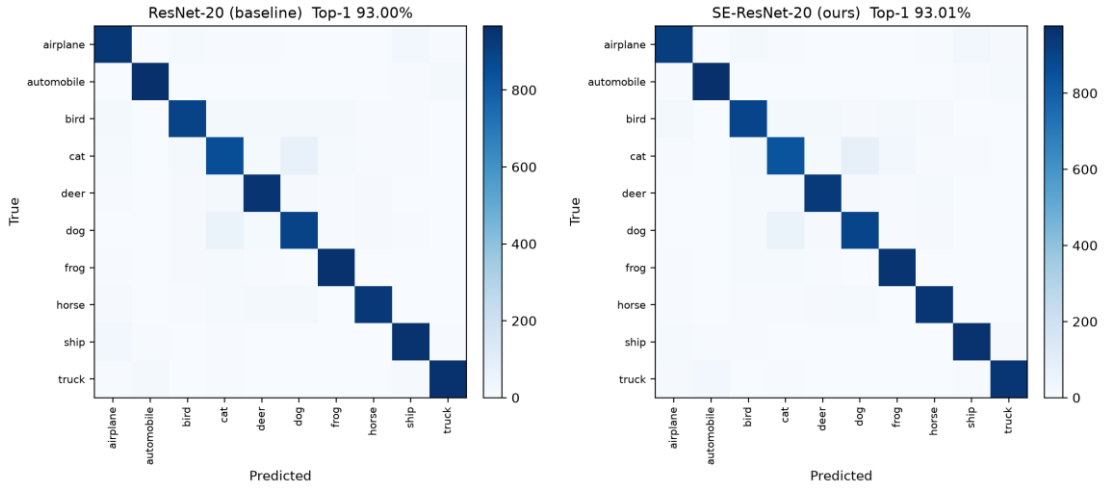


图 4-3 ResNet-20（左）与 SE-ResNet-20（右）的混淆矩阵

表 4-7 各类别准确率对比

类别	ResNet-20/%	SE-ResNet-20/%	差值
飞机	93.70	92.70	-1.00
汽车	96.70	97.70	+1.00
鸟	89.50	89.80	+0.30
猫	85.50	84.00	-1.50
鹿	94.60	93.80	-0.80
狗	89.30	89.90	+0.60
蛙	95.90	95.60	-0.30
马	93.60	95.20	+1.60
船	95.50	96.20	+0.70
卡车	95.70	95.20	-0.50

从混淆矩阵看，两个模型的错误都高度集中：猫↔狗、鸟↔飞机、鹿↔马、汽车↔卡车是四组主要混淆对，这与 CIFAR-10 的类内差异大、类间差异小的特点一致。更重要的是，SE 的类别级差值呈正负交替：马、汽车、船 有所上升，而 鹿、飞机、猫 则出现同等幅度的下降，10 个类别的平均差值仅 0.01 个百分点。这说明通道注意力并没有“普遍提升判别力”，而只是把误差在类别之间重新分配了一次。

这一现象可以这样理解：SE 通过全局平均池化得到一个与空间位置无关的通道描述子，再据此重加权。对于 32×32 的小图，全局池化已经损失了大部分空间信息，而 16/32/64 的通道数经 r=16 压缩后瓶颈仅剩 4 维，可学习的通道组合非常有限。因此 SE 更像是在做一次轻微的、带噪声的特征缩放，其效果接近于对训练过程施加随机扰动 —— 这既解释了类别间的正负抵消，也解释了总体精度的不变。

4.7 计算开销与精度—效率权衡

除精度外，实际部署更关心单位算力换来的精度。表 4-8 汇总了 7 个模型的参数量、权重体积、单张延迟与吞吐，图 4-4 给出精度—参数量散点。

表 4-8 参数量、模型体积与推理开销（统一测量流程）

模型	参数量	权重/MB	单张延迟/ms	吞吐/(img·s⁻¹)	MFLOPs
ResNet-20	0.27M	1.1	1.85	15852	81.6
ResNet-32	0.47M	1.9	2.91	10797	138.2
ResNet-56	0.86M	3.6	4.98	6188	251.5
VGG-16-BN	15.25M	61.1	2.23	8014	627.5
MobileNetV2	2.24M	9.2	3.92	4588	175.9
ResNet-20（自训练）	0.27M	1.1	1.89	17197	81.6
SE-ResNet-20（自训练）	0.28M	1.1	3.08	10164	81.6

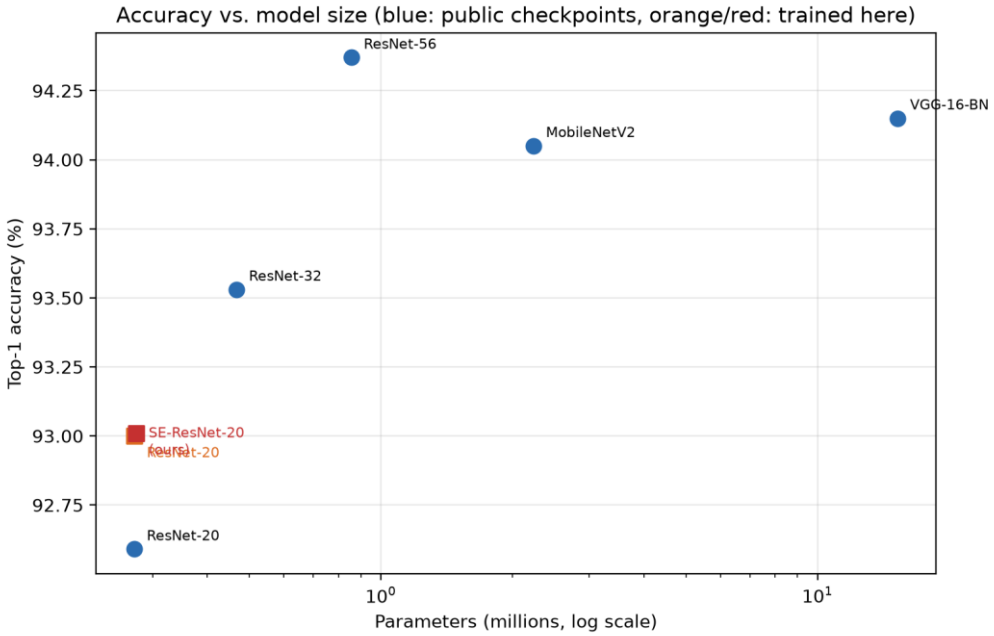


图 4-4 参数量与 Top-1 准确率的关系（对数横轴）

表 4-8 中最反直觉的一组对比是 VGG-16-BN 与 ResNet-56：前者参数量 15.3M，是后者（0.86M）的 17.8 倍，但单张延迟只有 2.23 ms，反而比 ResNet-56 的 4.98 ms 快 2.2 倍。原因在于二者的并行结构不同：VGG 由少数几个宽通道的大卷积堆叠而成，每次卷积的通道数达 256～512，能充分利用 GPU 的并行单元；而 ResNet-56 有 56 层、通道数仅 16～64，串联的 short-cut 与逐层小卷积使内核启动和访存开销占据主导。这一对比说明，参数量与延迟之间并不是单调关系，“小模型一定快”在 GPU 上并不成立。

MobileNetV2 是另一个例子：它的参数量只有 2.2M，延迟却高达 3.92 ms，是所有预训练模型中最慢的。深度可分离卷积把一次标准卷积拆成逐通道卷积与 1×1 卷积两步，虽然显著减少了乘加量，却引入了更多的内存访问与更低的算术强度，在 GPU 上反而吃亏——这与移动端 CPU 上的结论恰好相反。

把本文的两个自训练模型放进同一张表，结论更为直接：SE-ResNet-20 的参数量只比基线多 275,162 个（+0.99%），乘加量完全相同（81.6 MFLOPs），但单张延迟从 1.89 ms 升到 3.08 ms，增幅达 62.96%。其原因在于 SE 引入的全局池化与两层小全连接属于典型的“访存受限 + 算子启动开销”操作：通道数只有 16～64，每次运算的数据量很小，难以填满 GPU 的并行单元，却要为每个残差块额外付出一次池化、两次矩阵乘与若干次内核启动。换句话说，SE 的代价并不体现在 FLOPs 上，而体现在延迟上——这正是仅比较参数量或 FLOPs 时最容易忽略的部分。

综合精度与开销可以看出：在 0.27M 参数这一档，把预算花在通道注意力上并不划算；相比之下，把 ResNet-20 加深到 ResNet-32（参数量 +71%）能稳定换来 0.94 个百分点的提升。若必须在低预算下改进，更值得尝试的是数据增强、训练时长或标签平滑[18]等“零推理开销”的手段，而不是在推理路径上增加算子。

4.8 讨论

结合上述实验，可以对本文引言中提出的判断作出回应。

第一，关于“复现偏差”。5 个预训练模型中有 4 个与公布值的偏差不超过 0.01 个百分点，说明统一口径下的复现是可靠的；MobileNetV2 的 0.26 个百分点偏差则提醒我们，公开数字在缺少评测脚本与逐类结果时不宜直接引用。本文把每个数字都落到 JSON/CSV 文件的做法，正是为了避免这类不可追溯的偏差。

第二，关于“通道注意力的净效应”。在严格控制变量的条件下，SE 带来的是 +0.01 个百分点的精度变化与 62.96% 的延迟增加。把这一结果与“加深网络”这一更朴素的手段相比更能说明问题：ResNet-20 → ResNet-32 的参数量增加 71%，换来 0.94 个百分点的稳定提升；而 SE 只增加 0.99% 的参数，却没有可测的精度回报。在参数预算受限时，加宽或加深主干仍是比插入注意力模块更可靠的选择。

第三，关于“为什么没有增益”。本文认为原因有三。其一是容量瓶颈：在 0.27M 参数、32×32 输入、10 类的设定下，模型的限制主要来自数据量与优化过程，而非“通道选择能力”，SE 想解决的问题在这一规模上并不突出。其二是表达受限：通道数仅 16～64，经 r=16 压缩后瓶颈维度只有 4，可学习的通道组合太少，重加权接近于一个带噪声的缩放。其三是噪声地板：末段逐轮标准差约 1.11 个百分点，单次运行无法分辨 0.2 个百分点以下的差异；要宣称“+0.5% 的提升”，至少需要多个随机种子的重复实验。这三点共同解释了为何文献中在 ImageNet 上有效的结论，不能直接外推到 CIFAR 的小模型。

本文的局限也很明显。其一，仅验证了 ResNet-20 一种深度，SE 在更深或更宽结构上的收益是否同样为零尚不清楚；其二，受算力限制，每个配置只训练了一个随机种子，结论的统计置信度有限；其三，延迟测量在单卡笔记本 GPU 上完成，数值会随硬件与驱动变化，跨设备的绝对值不可直接比较，但同一设备内的相对关系是稳定的。

5 结论

5.1 结论

本文围绕 CIFAR-10 图像分类完成了复现与受控对照两项工作。在复现方面，5 个公开预训练模型在完整测试集上重新评测，Top-1 准确率分别为 92.59%、93.53%、94.37%、94.15% 与 94.05%，其中 4 个与公布值的偏差不超过 0.01 个百分点，验证了评测流程的正确性，并发现 MobileNetV2 存在 0.26 个百分点的正向偏差，提示公开数字需要重新测量后才能引用。

在对照实验方面，本文在 ResNet-20 的每个残差块后引入 SE 模块，在与基线完全相同的训练协议下从头训练。SE-ResNet-20 的 Top-1 为 93.01%，基线为 93.00%，差值 +0.01 个百分点，远小于末段逐轮波动；参数量增加 0.99%，单张推理延迟却增加 62.96%。类别级分析显示各类别差值正负交替、均值为零，说明 SE 只是重排了误差结构。据此本文的结论是：在约 0.27M 参数、32×32 输入的场景下，通道注意力不构成有效的精度—开销改进。

这一负结果本身具有参考价值。它提醒我们，文献中“加注意力即涨点”的经验依赖于具体的容量尺度与硬件条件；在轻量化模型中，真正稀缺的往往不是参数，而是推理延迟预算，因此任何加在推理路径上的算子都应先做代价评估。

从工程角度看，若目标是精度，优先选择加深/加宽主干（ResNet-32 比 ResNet-20 高 0.94 个百分点）或改进训练策略（更长的训练、更强的增强）；若目标是效率，则应优先考虑结构性的轻量化设计（如深度可分离卷积）而非注意力模块。VGG-16-BN 虽然取得了最高绝对精度，但参数量是 ResNet-56 的 17.8 倍、精度还低 0.22 个百分点，是“参数效率最低”的典型。

5.2 展望

后续工作可从三个方向展开。其一，对每个配置训练 3～5 个随机种子，给出均值与置信区间，使“有无提升”的判断具备统计意义；其二，在 ResNet-56、WideResNet 等更大容量结构上重复本文的单变量实验，检验通道注意力的收益是否随容量增长而出现；其三，把 SE 与空间注意力（CBAM）、轻量卷积（深度可分离、分组卷积）结合，并在 CPU、移动端等不同硬件上测量延迟，以判断本文的“延迟代价”结论是否具有跨平台一致性。此外，把评测扩展到 CIFAR-100 与 Tiny-ImageNet，也有助于判断结论的普适性。

参考文献

[1] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks[C]//Advances in Neural Information Processing Systems. 2012: 1097-1105.

[2] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[C]//International Conference on Learning Representations. 2015.

[3] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2016: 770-778.

[4] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2018: 7132-7141.

[5] Ioffe S, Szegedy C. Batch normalization: accelerating deep network training by reducing internal covariate shift[C]//International Conference on Machine Learning. 2015: 448-456.

[6] He K, Zhang X, Ren S, et al. Identity mappings in deep residual networks[C]//European Conference on Computer Vision. 2016: 630-645.
[7] Zagoruyko S, Komodakis N. Wide residual networks[C]//British Machine Vision Conference. 2016.
[8] Xie S, Girshick R, Dollár P, et al. Aggregated residual transformations for deep neural networks[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2017: 1492-1500.
[9] Huang G, Liu Z, van der Maaten L, et al. Densely connected convolutional networks[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2017: 4700-4708.
[10] Sandler M, Howard A, Zhu M, et al. MobileNetV2: inverted residuals and linear bottlenecks[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2018: 4510-4520.
[11] Ma N, Zhang X, Zheng H T, et al. ShuffleNet V2: practical guidelines for efficient CNN architecture design[C]//European Conference on Computer Vision. 2018: 116-131.
[12] Woo S, Park J, Lee J Y, et al. CBAM: convolutional block attention module[C]//European Conference on Computer Vision. 2018: 3-19.
[13] Wang Q, Wu B, Zhu P, et al. ECA-Net: efficient channel attention for deep convolutional neural networks[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2020: 11534-11542.
[14] Krizhevsky A. Learning multiple layers of features from tiny images[R]. Toronto: University of Toronto, 2009.
[15] Chen Y. pytorch-cifar-models: pretrained models on CIFAR10/100 in PyTorch[EB/OL]. https://github.com/chenyaofo/pytorch-cifar-models, 2025-05-17.
[16] He K, Zhang X, Ren S, et al. Delving deep into rectifiers: surpassing human-level performance on ImageNet classification[C]//IEEE International Conference on Computer Vision. 2015: 1026-1034.
[17] Loshchilov I, Hutter F. SGDR: stochastic gradient descent with warm restarts[C]//International Conference on Learning Representations. 2017.
[18] Szegedy C, Vanhoucke V, Ioffe S, et al. Rethinking the inception architecture for computer vision[C]//IEEE Conference on Computer Vision and Pattern Recognition. 2016: 2818-2826.

附录 A 核心代码

本附录给出改进方法与训练流程的核心实现。完整工程包含评估、训练、建模、绘图与排版共 15 个 Python 脚本，随论文以代码包形式提交，解压至工程根目录即可复现全部结果。

A.1 SE 模块与残差块（se_resnet.py 节选）

```
class SEBlock(nn.Module):
    def __init__(self, channels, reduction=16):
        super().__init__()
        hidden = max(channels // reduction, 4)
        self.pool = nn.AdaptiveAvgPool2d(1)
        self.fc = nn.Sequential(
            nn.Linear(channels, hidden, bias=False),
            nn.ReLU(inplace=True),
            nn.Linear(hidden, channels, bias=False),
            nn.Sigmoid())

    def forward(self, x):
        b, c, _, _ = x.shape
        w = self.pool(x).view(b, c)
        w = self.fc(w).view(b, c, 1, 1)
        return x * w

class BasicBlock(nn.Module):
    def forward(self, x):
        out = torch.relu(self.bn1(self.conv1(x)))
        out = self.bn2(self.conv2(out))
        out = self.se(out)            # SE 仅在对照模型中生效
        out = out + self.shortcut(x)
        return torch.relu(out)
```

A.2 训练主循环（train.py 节选）

```
optimizer = torch.optim.SGD(model.parameters(), lr=0.1, momentum=0.9,
                            weight_decay=5e-4, nesterov=True)
```

```
scheduler = torch.optim.lr_scheduler.CosineAnnealingLR(optimizer, T_max=200)
criterion = nn.CrossEntropyLoss()

for epoch in range(1, epochs + 1):
    model.train()
    for images, targets in train_loader:
        images, targets = images.cuda(), targets.cuda()
        optimizer.zero_grad(set_to_none=True)
        loss = criterion(model(images), targets)
        loss.backward()
        optimizer.step()
    test_loss, test_acc = evaluate(model, test_loader, criterion, device)
    scheduler.step()
    log_epoch(epoch, train_loss, train_acc, test_loss, test_acc)
```

附录 B 权重文件清单

表 B-1 列出本文用到的全部权重文件。其中“公开权重”为 pytorch-cifar-models 仓库发布的 checkpoint，“自训练权重”为本文运行 train.py 得到的最优模型。两种权重均随论文提交，并记录 SHA-256 前 16 位以便校验。

表 B-1 权重文件清单

文件	类型	大小/MB	SHA-256（前 16 位）	来源
cifar10_resnet20-4118986f.pt	公开预训练权重	1.1	4118986f0df73003	chenyaofo/pytorch-cifar-models
cifar10_resnet32-ef93fc4d.pt	公开预训练权重	1.9	ef93fc4d3ea83c08	chenyaofo/pytorch-cifar-models
cifar10_resnet56-187c023a.pt	公开预训练权重	3.6	187c023aee0c9cf3	chenyaofo/pytorch-cifar-models
cifar10_vgg16_bn-6ee7ea24.pt	公开预训练权重	61.1	6ee7ea24b52cfbbe	chenyaofo/pytorch-cifar-models
cifar10_mobilenetv2_x1_0-fe6a5b48.pt	公开预训练权重	9.2	fe6a5b4808c9b1b7	chenyaofo/pytorch-cifar-models
resnet20_best.pt	本文自训练权重	1.1	23fb5d87accbdab8	train.py (this work)
se_resnet20_best.pt	本文自训练权重	1.1	65fdeb1029e6aacb	train.py (this work)